Dokumentazio teknikoa · Documentación técnica

Proiektua / Proyecto: «Zenbat buru?» — Bizkaian jaiotzen diren abereak, banan-banan / «¿Cuántas cabezas?» — Las cabezas de ganado que nacen en Bizkaia, una a una

Lana ikusgai / Trabajo publicado: https://zenbatburu.berezuma.com

Kodea eta datuak / Código y datos: https://github.com/berezuma/zenbatburu

Kategoria / Categoría: 1 · Datuen bistaratzea / Visualización de datos

Egilea / Autor: Beñat

Deialdia / Convocatoria: Datu Kazetaritzaren Erronkaren Sariak 2026 · Premios al reto del periodismo de datos 2026. Izapidea / Trámite: 3104. Aurkezpen-epea / Plazo: 2026-11-20.

EUSKARAZ

1 · Erabilitako datu-iturriak

Open Data Bizkaia ataria, `explotaciones-ganaderas` datu-multzoa. https://www.opendatabizkaia.eus/es/catalogo/explotaciones-ganaderas

Datu-multzo horrek hiru taula-mota ditu pakete berean, eta hirurak erabili dira, CKAN `datastore_search` APIaren bidez eskuratuta:

TAULA	ILARAK	EREMUAK	ALDIA
Ustiategien erregistroa	52.488	17	2021–2025
Abereen jaiotzak	84.058	12	2023–2025
Abereen mugimenduak	63.809	20	2023–2025

Ez da beste daturik erabili, salbuespen bakar batekin: **arrazen egoera ofiziala**, 81/2015 Dekretuaren eranskinetik hartua (Euskal Arraza Autoktonoen Katalogo Ofiziala, EHAA 110, 2015-06-15). Xedapen ofizial bat da, eta orrian esplizituki aitortzen da. Guk ez dugu arrazarik sailkatu.

2 · Lan-prozesua

Eskuratzea. `build.py` script batek datu-multzoaren hamaika baliabideak jaisten ditu CKAN APItik, orrikatuta, eta taula-motaren arabera hiru fitxategitan batzen. Oharra: atariaren suebakiak `Mozilla/5.0` User-Agenta ukatzen du eta HTML bat itzultzen du JSONaren ordez; Pythonen lehenetsiak funtzionatzen du.

Hautaketa. Jaiotzen taula da ardatza, abere bakoitza ilara bat delako: identifikazioa, espeziea, arraza, sexua, jaiotze-data, udalerria eta ustiategia. **2023, 2024 eta 2025 urteak bakarrik** hartzen dira: beste 13 ilara dago, 2008tik 2026ra sakabanatuta, eta urte horiek ez daude osorik. Ustiategien taulak testuingurua ematen du, eta mugimenduenak jaio ondoren zer gertatzen den.

Tratamendua. `compact.py` script batek lau arazo konpontzen ditu:

- *Identifikazio errepikatuak.* 11 ilarak abere bera bitan zerrendatzen zuten; behin bakarrik zenbatzen dira. Emaitza: **84.034 abere**.
- *Espezie-izenak taulaz taula aldatzen dira:* jaiotzetan «Bovinos», ustiategietan «Bovidos»; «Caballo» eta «Asno» batetik, «Équidos» bestetik. Mapa dokumentatu batekin bateratzen dira.
- *Arrazak bi mailatan etiketatuta.* Iturriak batzuetan familia idazten du («LATXA») eta batzuetan aldaera («LATXA CARA NEGRA»), erregistratzailearen arabera. Horrek aldaeren serieak fidagarri gabe uzten ditu: aldaera baten beherakada etiketatze-aldaketa izan daiteke. **Dena familia mailan neurtzen da**, eta aldaerak informazio gisa gordetzen dira, ez serie gisa. 99 etiketa → 92 familia.
- *Kodeak Excel moduan bilduta* (`="022"`) eta maiuskula/minuskula nahasiak, normalizatuta. Eremuen izenak elebidunak dira («UDALERRIA/MUNICIPIO»), eta izen bat bestearen barruan dago: `LUGAR_DESTINO` bilatzeak `CODIGO_LUGAR_DESTINO` ere harrapatzen du, eta kodea itzultzen du izenaren ordez. Datu-multzo hau berrerabiltzen duenak **zehatz** bilatu behar du, azpikateaz fidatu gabe.

Hitzak. Erregistroan dagoena ez da «animalia» orokorra: *abereak* dira, abeltzaintzako ustiategietan jaioak eta banan-banan identifikatuak. Horregatik erabiltzen da *abere* orri osoan eta ez *animalia* — txakur bat ere animalia da, eta ez dago hemen. Gaztelaniazko bertsioan *ganado* eta *cabezas* dira termino baliokideak, eta ez *animal* soila.

Analisia. Hiru aurkikuntza atera dira datuetatik, eta hirurak datuen beraien mugei buruzkoak dira, ez bakarrik edukiari buruzkoak:

1. *Sexuaren ratioa.* Behietan emeak % 51,9 dira — biologiak hori ematen du. Ardietan erregistratutako abereen % 90,9 emeak dira, eta ahuntzetan % 87,5. Erregistroak ez ditu jaiotza guztiak biltzen: ustiategitik lehenago ateratzen direnak ez dira zerrendara iristen. Orrian ez da esaten *zergatik* gertatzen den — erregistroak ez du azaltzen —; esaten dena da zifra hori dela erregistroaren mugaren frogarik argiena.
2. *Egunen biribiltzea.* Abereen % 16,1 hilabete baten lehen egunean dago idatzita (13.521 abere hamabi egunetan): ardietan % 38,6, behietan % 4,5. Aurkikuntza hori bistaratzea egiten ari ginela agertu zen — hamabi zutabe besteak baino askoz luzeagoak—, eta proiektuaren ardatz bihurtu zen. Ondorioa: **ez da egun bati buruzko baieztapenik egiten orri osoan**; hilabetea da neurria.
3. *Katalogo ofiziala eta errealitatea.* 81/2015 Dekretuko hamalau abere-arrazatatik hamaikak dute jaiotzarik erregistroan. Eta arrisku-mailak ez du norabidea iragartzen: Azpigorri «kritikoa» erdira jaitsi da bi urtean (698 → 337), eta Monchina, «kritikoa» ere bai, igo egin da (348 → 440).

Egiaztapena. `verify.py` script batek orrian argitaratutako **53 zifra** iturri gordinetik berriro kalkulatzen ditu, trinkotze-prozesutik erabat independenteki (beste kode-bide bat, beste egitura bat). Grafikoak eta taulak datu trinkotuetatik sortzen dira zuzenean; egiaztapenak eskuz idatzitako testuko zifrak ere kontrolatzen ditu. **Hiru desadostasun** atzeman zituen argitaratu aurretik, eta hirurak zuzendu ziren:

- urteko guztizkoak bikoiztuak kendu aurretikoak ziren (29.626 → 29.619);
- «arkumeen % 59 neguan» idatzita zegoen, eta % 58,3 da;
- «moxalak hamabi aldiz gutxiago urtarrilean» idatzita zegoen, eta hogeita hiru aldiz dira.

3 · Tresnak eta teknikak

Datuak: Python 3, liburutegi gehigarririk gabe (`urllib`, `json`, `collections`, `re`, `unicodedata`, `base64`, `struct`).

Bistaratzea: HTML, CSS eta JavaScript eskuz idatziak, **kanpo-liburutegirik gabe**. Eszena nagusia `<canvas>` bat da: 84.034 marratxo erradial fotograma bakoitzean, bakoitza abere bat, bere jaiotze-eguneko angeluan. Eguna → angelua mapaketa bakarra da eszena guztietan, eta horregatik marratxoak **erradialki bakarrik** mugitzen dira: begiak abere berberak jarraitu ahal die eraztun handi bakarra bost gurpil bihurtzen denean. Grafiko estatikoak SVG dira.

Formatu trinkoa: abere bakoitza lau byte da — eguna, urtea, espeziea eta sexua zenbaki bakarrean bilduta (`Uint16`), eta arraza eta udalerria byte bana —, base64-an kodetuta. 147 MB gordin → **459 KB**, orriak datu guztiak barruan eraman ditzan, eskaera gehigarririk gabe.

Eskala-erabakia: hilaren lehen eguneko zutabeak gainerakoak baino zortzi aldiz luzeagoak dira. Gehienekoarekin eskalatuz gero, gainerako urtea ezabatuko litzateke; horregatik 98. pertzentilarekin

eskalatzen da, zutabe horiek **moztuta** marrazten dira, eta **benetako kopurua puntan idazten da**. Ezer ez da ezkutatzen.

Errepikagarritasuna: script bat datuak jaisteko, beste bat garbitzeko, beste bat egiaztatzeko, beste bat orria muntatzeko. Prozesu osoa hutsetik errepika daiteke.

4 · Erabilgarritasuna

Elebiduna (euskara/gaztelania), egoera URLan gordetzen duena esteka partekagarrietarako, teklatuz nabigagarria, CSV gisa deskargagarria, pantaila txikietara egokitua (390 px-tik gora probatuta) eta paperean inprimagarria. Mugimendua murriztea eskatzen duten erabiltzaileentzat (`prefers-reduced-motion`) animazioak eten egiten dira. JavaScriptik gabe, albistearen laburpena agertzen da, bi hizkuntzatan.

Datu pertsonalak: ez dago izen-abizenik datu-multzoan ez orrian. Ustiategiak kodez identifikatzen dira (`ES480220006941`), eta orriak ez du ustiategi-koderik erakusten: udalerri mailan agregatzen da beti.

EN CASTELLANO

1 · Fuentes de datos utilizadas

Se indica expresamente el **conjunto de datos del portal Open Data Bizkaia** utilizado, que es el único empleado en el proyecto:

`explotaciones-ganaderas` — Registro de explotaciones ganaderas. https://www.opendatabizkaia.eus/es/catalogo/explotaciones-ganaderas

Ese conjunto contiene tres tipos de tabla en el mismo paquete, y se han usado los tres, obtenidos mediante la API CKAN `datastore_search`:

TABLA	FILAS	CAMPOS	PERIODO
Registro de explotaciones	52.488	17	2021–2025
Nacimientos de ganado	84.058	12	2023–2025
Movimientos de ganado	63.809	20	2023–2025

No se ha empleado ninguna otra fuente, con una única excepción: el **estado oficial de las razas**, tomado del anexo del Decreto 81/2015 (Catálogo Oficial de Razas Animales Autóctonas Vascas, BOPV 110, 15-06-2015). Es una disposición oficial, se acredita expresamente en la página, y la clasificación no es nuestra.

2 · Proceso de trabajo

Obtención. Un script `build.py` descarga los once recursos del conjunto desde la API CKAN, paginando, y los unifica en tres ficheros según el tipo de tabla. Nota: el cortafuegos del portal rechaza el User-Agent `Mozilla/5.0` y devuelve HTML en lugar de JSON; el agente por defecto de Python sí funciona.

Selección. La tabla de nacimientos es el eje, porque cada cabeza es una fila: identificación, especie, raza, sexo, fecha de nacimiento, municipio y explotación. Se toman **solo 2023, 2024 y 2025**: hay otras 13 filas dispersas de 2008 a 2026, y esos años no están completos. La tabla de explotaciones aporta contexto, y la de movimientos, qué ocurre después de nacer.

Tratamiento. Un script `compact.py` resuelve cuatro problemas:

- *Identificaciones repetidas.* 11 filas listaban el mismo animal dos veces; se cuentan una sola vez. Resultado: **84.034 cabezas de ganado**.
- *Los nombres de especie cambian entre tablas:* «Bovinos» en nacimientos, «Bovidos» en explotaciones; «Caballo» y «Asno» por un lado, «Équidos» por otro. Se unifican con un mapa documentado.
- *Razas etiquetadas en dos niveles.* La fuente escribe a veces la familia («LATXA») y a veces la variedad («LATXA CARA NEGRA»), según quien registre. Eso deja las series por variedad sin fiabilidad: la caída de una variedad puede ser un cambio de etiquetado. **Todo se mide a nivel de familia**, y las variedades se guardan como información, no como serie. 99 etiquetas → 92 familias.
- *Códigos envueltos al estilo Excel* (`="022"`) y mayúsculas mezcladas, normalizados. Los nombres de campo son bilingües («UDALERRIA/MUNICIPIO») y hay que un nombre está contenido en otro: buscar

`LUGAR_DESTINO` captura también `CODIGO_LUGAR_DESTINO` y devuelve el código en lugar del nombre. Quien reutilice este conjunto debe buscar de forma **exacta**, sin fiarse de la subcadena.

Las palabras. Lo que hay en el registro no son «animales» en general: son *cabezas de ganado*, nacidas en explotaciones ganaderas e identificadas una a una. Por eso se usa *ganado* y *cabezas*, y no *animal* a secas — un perro también es un animal, y aquí no está. En euskera el término es *abere*, que significa exactamente eso.

Análisis. Del conjunto salen tres hallazgos, y los tres hablan de los límites del propio registro, no solo de su contenido:

1. *La ratio de sexos.* En bovinos las hembras son el 51,9 % — eso es lo que da la biología. En ovinos, el 90,9 % de lo registrado son hembras, y en caprinos el 87,5 %. El registro no recoge todos los nacimientos: los que salen antes de la explotación no llegan a la lista. La página no afirma *por qué* ocurre —el registro no lo explica—; afirma que esa cifra es la prueba más clara del límite.
2. *El redondeo de los días.* El 16,1 % de las cabezas está anotado el día 1 de algún mes (13.521 cabezas en doce días): en ovinos el 38,6 %, en bovinos el 4,5 %. El hallazgo apareció mientras se construía la visualización —doce columnas mucho más largas que las demás— y acabó siendo el eje del proyecto. Consecuencia: **no se hace ninguna afirmación sobre días** en toda la página; la unidad es el mes.
3. *El catálogo oficial frente a la realidad.* De las catorce razas ganaderas del Decreto 81/2015, once tienen nacimientos en el registro. Y el nivel de riesgo no anticipa la dirección: la Azpigorri, «crítica», ha caído a la mitad en dos años (698 → 337), y la Monchina, también «crítica», ha subido (348 → 440).

Verificación. Un script `verify.py` recalcula las **53 cifras** publicadas desde la fuente en bruto, de forma completamente independiente al proceso de compactación (otro camino de código, otra estructura). Los gráficos y las tablas salen directamente de los datos compactados; la verificación controla además las cifras escritas a mano en el texto. Detectó **tres discrepancias** antes de publicar, y las tres se corrigieron:

- los totales anuales eran previos a eliminar duplicados (29.626 → 29.619);
- se había escrito «el 59 % de los corderos en invierno», y es el 58,3 %;
- se había escrito «doce veces menos potros en enero», y son veintitrés.

3 · Herramientas y técnicas

Datos: Python 3, sin librerías adicionales (`urllib`, `json`, `collections`, `re`, `unicodedata`, `base64`, `struct`).

Visualización: HTML, CSS y JavaScript escritos a mano, **sin librerías externas**. La escena principal es un `<canvas>`: 84.034 marcas radiales en cada fotograma, cada una un animal, en el ángulo de su día de nacimiento. La correspondencia día → ángulo es única en todas las escenas, y por eso las marcas solo se mueven **en radio**: el ojo puede seguir a los mismos animales cuando el anillo grande se convierte en cinco ruedas. Los gráficos estáticos son SVG.

Formato compacto: cada cabeza son cuatro bytes —día, año, especie y sexo en un solo número (`Uint16`), y raza y municipio un byte cada uno—, codificados en base64. 147 MB en bruto → **459 KB**, para que la página lleve todos los datos dentro sin peticiones adicionales.

Una decisión de escala: las columnas del día 1 de cada mes son ocho veces más largas que el resto. Escalar por el máximo borraría el resto del año; por eso se escala por el percentil 98, esas columnas se dibujan

recortadas, y **la cifra real se escribe en la punta**. No se oculta nada.

Reproducibilidad: un script para descargar, otro para limpiar, otro para verificar, otro para montar la página. Todo el proceso puede repetirse desde cero.

4 · Usabilidad

Bilingüe (euskera/castellano), con el estado guardado en la URL para compartir enlaces, navegable con teclado, descargable en CSV, adaptada a pantallas pequeñas (probada desde 390 px) e imprimible en papel. Para quienes piden movimiento reducido (`prefers-reduced-motion`) las animaciones se detienen. Sin JavaScript, se muestra el resumen de la noticia en los dos idiomas.

Datos personales: no hay nombres de personas ni en el conjunto de datos ni en la página. Las explotaciones se identifican por código (`ES480220006941`), y la página no muestra ningún código de explotación: siempre agrega a nivel de municipio.